Prédire et expliquer le départ des clients d'un opérateur télécom

Challenge 1 · Classification explicable · Data Mining II3-IF · ENSI 2026-2027 · Cas n° 13 : Telco Customer Churn (IBM)

7 043
clients

26,5 %
partent

0,848
AUC-ROC, XGBoost (meilleur)

0,846
AUC-ROC, rég. logistique (retenue)

71 %
rappel au seuil 0,35

1. Problème métier

Un opérateur télécom perd 26,5 % de ses clients (1 869 sur 7 043). Objectif : repérer à l'avance les clients susceptibles de partir pour leur proposer une offre de fidélisation, et comprendre **pourquoi** un client est jugé à risque, afin de choisir l'action et de justifier le score.

2. Données

Telco Customer Churn (IBM), téléchargé automatiquement : 7 043 clients, 19 variables (profil, ancienneté, services souscrits, contrat, facturation). Cible : départ (Churn = Yes). 11 valeurs manquantes (TotalCharges) imputées par la médiane, encodage one-hot, standardisation, test de 25 % stratifié (1 761 clients, graine 42).

3. Modèles et résultats

Modèle	AUC-ROC	PR-AUC	Rappel	Précision
XGBoost	0,848	0,656	72 %	57 %
Random Forest	0,846	0,650	71 %	57 %
Régression logistique	0,846	0,633	71 %	55 %
k plus proches voisins	0,834	0,616	78 %	51 %
Arbre de décision	0,831	0,627	66 %	57 %

Rappel et précision sur la classe « départ », au seuil de décision 0,35. Hyperparamètres optimisés par grille (AUC, validation croisée à 3 plis). Meilleure AUC en vert. Les trois premiers modèles sont séparés de 0,002 d'AUC : écart non significatif sur un seul découpage.

4. Importance des variables selon le modèle

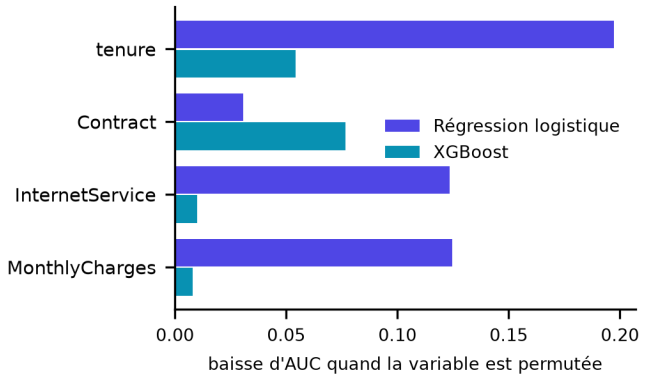

Importance par permutation (jeu de test). L'ancienneté domine pour la régression logistique, le type de contrat pour XGBoost : les deux modèles s'appuient sur les mêmes grandes familles de variables.

5. Ce que disent SHAP et LIME

- **Ce qui augmente le risque** (pour les deux modèles) : ancienneté courte, contrat mensuel, fibre optique, absence de sécurité en ligne et de support technique, paiement par chèque électronique.
- **Ce qui le réduit** : ancienneté élevée et contrat de 2 ans. L'effet d'un contrat d'un an est faible et varie selon le modèle.
- **Cohérence** : sur un client à 1 mois d'ancienneté (risque 88 %), SHAP et LIME concordent sur le signe des 10 variables comparées, partagent 4 des 5 premières et ont une corrélation de rang de 0,90. Résultat conforme à l'intuition métier.
- **Prudence** : MonthlyCharges est presque entièrement déterminée par les services souscrits (R^2 de 0,999) et TotalCharges vaut quasiment ancienneté × charges mensuelles. Ces variables se recouvrent : leurs contributions peuvent sembler paradoxales (charges élevées qui réduisent le risque chez un client récent) et changent d'une méthode à l'autre.

6. Variables sensibles et équité

Le modèle utilise sexe, senior, conjoint et personnes à charge. Leur poids SHAP est faible (0,0 % à 1,4 %), mais le modèle signale beaucoup plus de seniors : 30 points d'écart entre seniors et non-seniors, contre 18 points d'écart de départs réels (41,7 % contre 23,6 %). Même schéma pour les personnes à charge (25 points signalés contre 16 réels) ; pour le sexe, 2,6 points signalés contre 0,7 point réel. Au seuil 0,35, le modèle amplifie donc des écarts déjà présents. Retirer ces colonnes ne suffirait pas : d'autres variables (contrat, services) peuvent les remplacer.

7. Recommandations

- **Retenir la régression logistique** : AUC 0,846 contre 0,848 pour XGBoost, coefficients lisibles, explications stables. XGBoost seulement si son gain de PR-AUC (0,656 contre 0,633) compte pour la campagne.
- **Seuil 0,35** : rappel de 71 % pour 55 % de précision (régression logistique). À régler selon le coût d'une offre et la valeur d'un client.
- **Actions** : cibler d'abord les clients de moins d'un an en contrat mensuel ; proposer un engagement de 2 ans (le contrat est la variable la plus importante pour XGBoost) ; revoir l'offre fibre et les services de sécurité et de support.
- **Usage du score** : le réserver à des actions commerciales favorables au client, jamais à une décision défavorable ; suivre l'écart de signalement entre groupes.

8. Limites

Un seul jeu de données et un seul découpage train/test, sans intervalle de confiance. Les explications décrivent le modèle, pas des causes. Le seuil doit être calibré sur des coûts réels. Jeu d'exemple d'un seul opérateur.